

## 0 Logistická regrese

Logistická regrese predikuje pravděpodobnost jednotlivých hodnot vysvětlované proměnné. Pro binární klasifikaci  $Y \in \{0, 1\}$ , na kterou se omezíme, tedy vrací pravděpodobnost 1,  $P(Y = 1) \in [0, 1]$ .

### 0.1 Použití pro binární klasifikaci

#### 0.1.1 Sigmoida

V modelu použijeme lineární výraz  $\mathbf{w}^T \mathbf{x} = w_0 + w_1 x_1 + \dots + w_p x_p$ , který má však obor hodnot na celém  $\mathbb{R}$ . Tento výraz proto dosadíme do funkce, která je ostře rostoucí a má obor hodnot podmnožinu  $[0, 1]$ . V logistické regresi volíme sigmoidu

$$f(x) = \frac{e^x}{1 + e^x} = \frac{1}{1 + e^{-x}}$$

Jedná se o speciální případ logistické funkce

$$f(x) = \frac{L}{1 + e^{-k(x-x_0)}},$$

se supremem  $L = 1$ , koeficientem růstu  $k = 1$  a středem  $x_0 = 0$ .

Sigmoida má jako definiční obor celé  $\mathbb{R}$  a obor hodnot  $(0, 1)$ . Na celém definičním oboru je ostře rostoucí, limita pro  $x \rightarrow -\infty$  je 0 a pro  $x \rightarrow +\infty$  je 1. Také platí, že střed má v bodě 0:  $f(0) = \frac{1}{2}$ .

#### 0.1.2 Fungování modelu logistické regrese

Binární klasifikace vysvětlované proměnné  $Y \in \{0, 1\}$  s  $p$  příznaky  $X_1, \dots, X_p$  logistická regrese provede predikci pravděpodobnosti

$$P(Y = 1 \mid \mathbf{x}, \mathbf{w}) = \frac{e^{\mathbf{w}^T \mathbf{x}}}{1 + e^{\mathbf{w}^T \mathbf{x}}},$$

kde  $\mathbf{x} = (1, x_1, \dots, x_p)$  je vektor hodnot příznaků a  $\mathbf{w} = (w_0, \dots, w_p)$  je vektor koeficientů. Model zvolí 1 když  $P(Y = 1 \mid \mathbf{x}, \mathbf{w}) > 0.5$ , jinak predikuje 0.

### 0.2 Hranice rozhodnutí

Hranice rozhodnutí je dána rovnicí

$$P(Y = 1 \mid \mathbf{x}, \mathbf{w}) = 0.5 \quad \Leftrightarrow \quad \mathbf{w}^T \mathbf{x} = 0 \quad \Leftrightarrow \quad w_0 + w_1 x_1 + \dots + w_p x_p = 0$$

To odpovídá nadrovině v prostoru  $\mathbb{R}^p$ . Hranici tedy tvoří lineární varieta dimenze  $p - 1$ .

### 0.3 Logistická regrese jako MLE odhad

Vzhledem k tomu, že u logistické regrese predikujeme pravděpodobnost hodnot proměnné  $Y$ , nelze vyloženě měřit chybu takových odhadů a následně je minimalizovat jako u lineární regrese. Proto parametry  $\mathbf{w}$  odhadujeme MLE (maximum likelihood estimation) metodou maximální věrohodnosti.

#### 0.3.1 Myšlenka MLE odhadu

Pro parametry  $\mathbf{w} = (w_0, w_1, \dots, w_p)$  jsou pravděpodobnosti následující

$$p_1(\mathbf{x}; \mathbf{w}) = P(Y = 1 \mid \mathbf{x}, \mathbf{w}) = \frac{e^{\mathbf{w}^T \mathbf{x}}}{1 + e^{\mathbf{w}^T \mathbf{x}}}$$

$$p_0(\mathbf{x}; \mathbf{w}) = P(Y = 0 \mid \mathbf{x}, \mathbf{w}) = \frac{1}{1 + e^{\mathbf{w}^T \mathbf{x}}}$$

MLE je takový odhad parametrů, pro které je daná realizace náhodného výběru nejpravděpodobnější (má největší věrohodnost). Metoda maximální věrohodnosti formálně odhaduje hodnotu  $\hat{\mathbf{w}}$  parametru  $\mathbf{w}$ , která maximalizuje  $L(\mathbf{w}; \mathbf{X})$  na trénovacích datech  $\mathbf{X} = (\mathbf{x}_1, \dots, \mathbf{x}_N)$ , kde  $\mathbf{x}_i = (1, x_{i,1}, \dots, x_{i,p})$  jsou jednotlivé naměřené hodnoty:

$$\hat{\mathbf{w}} \in \left\{ \arg \max_{\mathbf{w} \in \mathbb{R}^{p+1}} L(\mathbf{w}; \mathbf{X}) \right\}, \quad \text{kde } L(\mathbf{w}; \mathbf{X}) = \prod_{i=1}^N p_{Y_i}(\mathbf{x}_i; \mathbf{w})$$

#### 0.3.2 Sestavení optimalizační úlohy pro trénování

Pro tuto funkci se snažíme nalézt maximum (nemusí existovat). Před zderivováním se však často vyplatí věrohodnost zlogaritmovat (log-likelihood), který je na  $(0, +\infty)$  prostý a ostře rostoucí a tudíž má maximum ve stejném bodě.

$$\begin{aligned} \ell(\mathbf{w}; \mathbf{X}) &= \ln L(\mathbf{w}; \mathbf{X}) = \sum_{i=1}^N \ln p_{Y_i}(\mathbf{x}_i; \mathbf{w}) \\ &= \sum_{i=1}^N Y_i \ln p_1(\mathbf{x}_i; \mathbf{w}) + (1 - Y_i) \ln p_0(\mathbf{x}_i; \mathbf{w}) = \dots \\ &= \sum_{i=1}^N \left( Y_i \mathbf{w}^T \mathbf{x}_i - \ln(1 + e^{\mathbf{w}^T \mathbf{x}_i}) \right) \end{aligned}$$

Parciální derivace a gradient vychází

$$\frac{\partial \ell(\mathbf{w}; \mathbf{X})}{\partial w_j} = \sum_{i=1}^N \left( Y_i x_{i,j} - \frac{e^{\mathbf{w}^T \mathbf{x}_i} \cdot x_{i,j}}{1 + e^{\mathbf{w}^T \mathbf{x}_i}} \right) = \sum_{i=1}^N x_{i,j} (Y_i - p_1(\mathbf{x}_i; \mathbf{w}))$$

$$\nabla \ell(\mathbf{w}; \mathbf{X}) = \mathbf{X}^T (\mathbf{Y} - \mathbf{P}), \quad \text{kde } \mathbf{P} = (p_1(\mathbf{x}_1; \mathbf{w}), \dots, p_1(\mathbf{x}_N; \mathbf{w}))^T$$

Náš odhad leží v bodě, kde věrohodnost nabývá maxima, což nalezneme položením gradientu nule:

$$\nabla \ell(\hat{\mathbf{w}}; \mathbf{X}) = \mathbf{X}^T (\mathbf{Y} - \hat{\mathbf{P}}) = \mathbf{0}$$

Zde neexistuje explicitní řešení a je třeba jej hledat numerickými aproximativními metodami (např. vícerozměrnou Newtonovou metodou lze ukázat, že řešení konverguje k lok. maximu, které je v případě logistické regrese současně globálním maximem).

Výpočet koeficientů logistické regrese je výpočetně náročný. Bez explicitního vzorce je výsledek jen aproximace a je možné, že počítač nic nevrátí (nepodaří se mu nalézt dostatečně dobrá aproximace).

Funkce  $\ell(\mathbf{w}; \mathbf{X})$  také žádné maximum mít nemusí. V takovém případě se numeric-kou metodou pouze snažíme hledat přibližné řešení  $\mathbf{X}^T (\mathbf{Y} - \hat{\mathbf{P}}) = \mathbf{0}$ .