

## 0 Statistické vlastnosti modelů

V modelu pro trénovací množinu  $\mathbf{Y} = \mathbf{X}\mathbf{w} + \varepsilon$  je  $\varepsilon$  náhodný vektor, z čehož plyne, že  $\mathbf{Y}$  je náhodný vektor, a tedy i  $\hat{\mathbf{w}}_\lambda$  je náhodný vektor.

### 0.1 Očekávaná chyba modelu

Protože je odhad  $\hat{\mathbf{w}}_\lambda$  náhodný vektor, můžeme pomocí kvadratické ztrátové funkce zkoumat očekávanou chybu predikce  $Y = \mathbf{w}^T \mathbf{x} + \varepsilon$  pomocí  $\hat{Y} = \hat{\mathbf{w}}_\lambda^T \mathbf{x}$ .

#### 0.1.1 Rozklad očekávané chyby modelu

Předpokládáme-li, nezávislost trénovací množiny s testovací množinou, tedy i nezávislost  $Y$  a  $\hat{Y}$ , pak lze očekávanou chybu spočítat jako

$$E L(Y, \hat{Y}) = E(Y - \hat{Y})^2 = \dots = \text{var } Y + E(\hat{Y} - E Y)^2 = \sigma^2 + \text{MSE}(\hat{Y})$$

První člen odpovídá Bayesovské chybě, která je dána náhodností modelu. Druhý člen značíme  $\text{MSE}(\hat{Y})$  (mean squared error), který se dá dále dělit na dva členy:

$$\text{MSE}(\hat{Y}) = E(\hat{Y} - E Y)^2 = \dots = (E \hat{Y} - E Y)^2 + E(\hat{Y} - E \hat{Y})^2 = (\text{bias } \hat{Y})^2 + \text{var } \hat{Y}$$

kde  $\text{bias } \hat{Y}$  značí vychýlení odhadu  $\hat{Y}$  a  $\text{var } \hat{Y}$  jeho rozptyl. Finální dekompozice očekávané chyby odhadu je

$$E L(Y, \hat{Y}) = \sigma^2 + (\text{bias } \hat{Y})^2 + \text{var } \hat{Y}$$

a skládá se z neodstranitelné Bayesovské chyby, kvadrátu vychýlení odhadu a rozptylu odhadu.

Tento rozklad je pouze teoretický, v praxi máme jen celkové MSE, které se snažíme minimalizovat.

### 0.2 Bias-variance tradeoff

Zpravidla s komplexitou modelu klesá bias (vychýlení), ale roste variance (rozptyl) – model se přeučuje.

U hřebenové regrese s rostoucím regulačním koeficientem klesá rozptyl (regularizace je silnější, odhad  $\hat{\mathbf{w}}$  je stabilnější), ale zároveň roste vychýlení (koeficienty více “dusíme” a jsou systematicky podhodnocované). Takovému chování v závislosti na hyperparametrech modelu se nazývá bias-variance tradeoff.

V praxi při ladění hřebenové regresi hledáme optimální  $\lambda$ , při které je MSE na validační množině  $(Y'_i, \mathbf{x}'_i)$  nejmenší. MSE odhadujeme

$$\text{MSE} = \frac{1}{n} \sum_{i=1}^n (Y'_i - \hat{\mathbf{w}}_\lambda^T \mathbf{x}'_i)^2$$

Při použití hřebenové regrese je rozumné příznaky standardizovat, aby byly rozsahově podobné a penalizované stejně. Příznaky  $X_i$  nahradíme

$$X_i \leftarrow \frac{X_i - \bar{X}_i}{\sqrt{s_{X_i}^2}}, \quad \text{kde} \quad \bar{X}_i = \frac{1}{N} \sum_{j=1}^N (X_i)_j \quad \text{a} \quad s_{X_i}^2 = \frac{1}{N-1} \sum_{j=1}^N (X_i - \bar{X}_i)^2$$

### 0.3 Nestrannost odhadu v metodou nejmenších čtverců

Protože je  $\hat{\mathbf{w}}_{\text{OLS}}$  bodový odhad (statistika) můžeme zkoumat zda je nestranný. Předpokládáme-li  $E\boldsymbol{\varepsilon} = 0$ , pak z linearity střední hodnoty platí

$$E\mathbf{Y} = E(\mathbf{X}\mathbf{w} + \boldsymbol{\varepsilon}) = E\mathbf{X}\mathbf{w} + E\boldsymbol{\varepsilon} = \mathbf{X}\mathbf{w}$$

Dále platí

$$\begin{aligned} E\hat{\mathbf{w}}_{\text{OLS}} &= E[(\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \mathbf{Y}] \\ &= (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T E[\mathbf{Y}] \\ &= (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \mathbf{X} \mathbf{w} = \mathbf{w} \end{aligned}$$

Z čehož plyne

$$E\hat{Y} = E(\hat{\mathbf{w}}_{\text{OLS}}^T \mathbf{x}) = E(\hat{\mathbf{w}}_{\text{OLS}})^T \mathbf{x} = \mathbf{w}^T \mathbf{x} = EY$$

$\hat{Y}$  je tedy nestranným bodovým odhadem  $EY$ . To znamená, že pro neregularizovanou lineární regresi platí, že je vychýlení nulové:

$$\text{bias } \hat{Y} = E\hat{Y} - EY = 0.$$