

0 Hřebenová regrese

Hřebenová nebo také L_2 regularizace, stejně jako lineární regrese, předpokládá lineární model $Y = \mathbf{w}^T \mathbf{x} + \varepsilon$. Nicméně navíc řeší problém kolinearit tím, že penalizuje vysoké hodnoty koeficientů \mathbf{w} vyjma interceptu.

0.1 Regularizovaný reziduální součet čtverců

Hřebenová regrese tedy minimalizuje následující reziduální součet čtverců

$$\text{RSS}_\lambda(\mathbf{w}) = \|\mathbf{Y} - \mathbf{X}\mathbf{w}\|^2 + \lambda \sum_{i=1}^p w_i^2$$

s regulačním členem $\lambda \geq 0$.

Pro $\lambda = 0$ dostáváme klasickou neregularizovanou lineární regresi. Intercept se nepenalizuje, protože ten jen zajišťuje $E\varepsilon = 0$.

0.2 Minimalizace regularizovaného RSS

Pro účely hřebenové regrese zavedeme

$$\mathbf{I}' = \begin{pmatrix} 0 & 0 & \cdots & 0 \\ 0 & 1 & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & 1 \end{pmatrix} \in \mathbb{R}^{p+1, p+1}$$

Regularizovaný RSS_λ lze vyjádřit jako

$$\begin{aligned} \text{RSS}_\lambda(\mathbf{w}) &= \|\mathbf{Y} - \mathbf{X}\mathbf{w}\|^2 + \lambda \sum_{i=1}^p w_i^2 \\ &= \|\mathbf{Y} - \mathbf{X}\mathbf{w}\|^2 + \lambda \mathbf{w}^T \mathbf{I}' \mathbf{w} \end{aligned}$$

Nalezneme parciální derivaci a následně gradient

$$\begin{aligned} \frac{\partial \text{RSS}(\mathbf{w})}{\partial w_j} &= \sum_{i=1}^N 2(Y_i - \mathbf{w}^T \mathbf{x}_i)(-x_{i,j}) + 2\lambda w_j \\ \nabla \text{RSS}(\mathbf{w}) &= \sum_{i=1}^N 2(Y_i - \mathbf{w}^T \mathbf{x}_i)(-\mathbf{x}_i) + 2\lambda \mathbf{I}' \mathbf{w} \\ &= -2\mathbf{X}^T(\mathbf{Y} - \mathbf{X}\mathbf{w}) + 2\lambda \mathbf{I}' \mathbf{w} \end{aligned}$$

A položením rovno nule obdržíme ekvivalent normální rovnice

$$\begin{aligned}\mathbf{X}^T \mathbf{Y} - \mathbf{X}^T \mathbf{X} \mathbf{w} - \lambda \mathbf{I}' \mathbf{w} &= 0 \\ \mathbf{X}^T \mathbf{Y} - (\mathbf{X}^T \mathbf{X} + \lambda \mathbf{I}') \mathbf{w} &= 0\end{aligned}$$

Hessova matice zde vychází

$$\mathbf{H}_{\text{RSS}_\lambda}(\mathbf{w}) = 2(\mathbf{X}^T \mathbf{X} + \lambda \mathbf{I}')$$

Pro libovolné $\mathbf{s} \in \mathbb{R}^{p+1}$, $\mathbf{s} \neq \mathbf{0}$, $\lambda > 0$ platí

$$\begin{aligned}\mathbf{s}^T (\mathbf{X}^T \mathbf{X} + \lambda \mathbf{I}') \mathbf{s} &= \mathbf{s}^T \mathbf{X}^T \mathbf{X} \mathbf{s} + \lambda \mathbf{s}^T \mathbf{I}' \mathbf{s} \\ &= \|\mathbf{X} \mathbf{s}\|^2 + \lambda \sum_{i=1}^p s_i^2 > 0,\end{aligned}$$

Matice $\mathbf{X}^T \mathbf{X} + \lambda \mathbf{I}'$ je tedy vždy pozitivně definitní a regulární a řešení normální rovnice pro regulované RSS_λ je jednoznačné.

$$\hat{\mathbf{w}}_\lambda = (\mathbf{X}^T \mathbf{X} + \lambda \mathbf{I}')^{-1} \mathbf{X}^T \mathbf{Y}$$

Predikce modelu je $\hat{Y} = \hat{\mathbf{w}}_\lambda^T \mathbf{x}$.

0.3 Modely báзовých funkcí

Model lineární regrese, případně hřebenové regrese, modeluje pouze lineární funkci. Množinu příznaků lze však rozšířit jejími transformovanými variantami.

0.3.1 Báзовé funkce

Pro $M \in \mathbb{N}$ zvolme M funkcí $\varphi_1, \dots, \varphi_M$ z \mathbb{R}^p do \mathbb{R} reprezentující transformace. Těmto funkcím říkáme báзовé funkce.

Modely báзовých funkcí se od předchozích lineárních regresních modelů liší pouze tím, že místo původního \mathbf{x} pracuje s $\boldsymbol{\varphi}(\mathbf{x}) := (1, \varphi_1(\mathbf{x}), \dots, \varphi_M(\mathbf{x}))^T$

0.3.2 Volba báзовých funkcí

Časté volby báзовých funkcí jsou

- $\varphi(\mathbf{x}) = x_i$ – původní příznaky
- $\varphi(\mathbf{x}) = x_i^2, x_i x_j$ – mocniny, součiny (polynomiální regrese)
- $\varphi(\mathbf{x}) = \log(x_i), \sqrt{x_i}, \sin(x_i)$ – nelineární transformace
- $\varphi(\mathbf{x}) = \mathbb{1}_A$ – indikátory (dělení prostoru)

0.3.3 Model

Model bázové funkce rozšiřuje možnosti hřebenové regrese a může jej dělat velmi mocným a sofistikovaným nástrojem.

$$\mathbf{x} \longrightarrow \boldsymbol{\varphi}(\mathbf{x}): \quad Y = \mathbf{w}_\lambda^T \boldsymbol{\varphi}(\mathbf{x}) + \varepsilon$$

Postup s transformovaným vektorem $\mathbf{x}' := \boldsymbol{\varphi}(\mathbf{x})$ je dál zcela analogický jako u hřebenové regrese a predikce modelu je $\hat{Y} = \hat{\mathbf{w}}_\lambda^T \boldsymbol{\varphi}(\mathbf{x})$.